Mit HealthDCAT-AP.de die richtigen Daten finden

Ein europäisches Metadatenmodell für das deutsche Gesundheitswesen

Durch standardisierte Metadaten hilft HealthDCAT-AP.de Forschenden, Datensätze leichter zu finden, zu verknüpfen und bereits vor Beschaffung festzustellen, ob sie für ihre Fragestellung nützlich sind

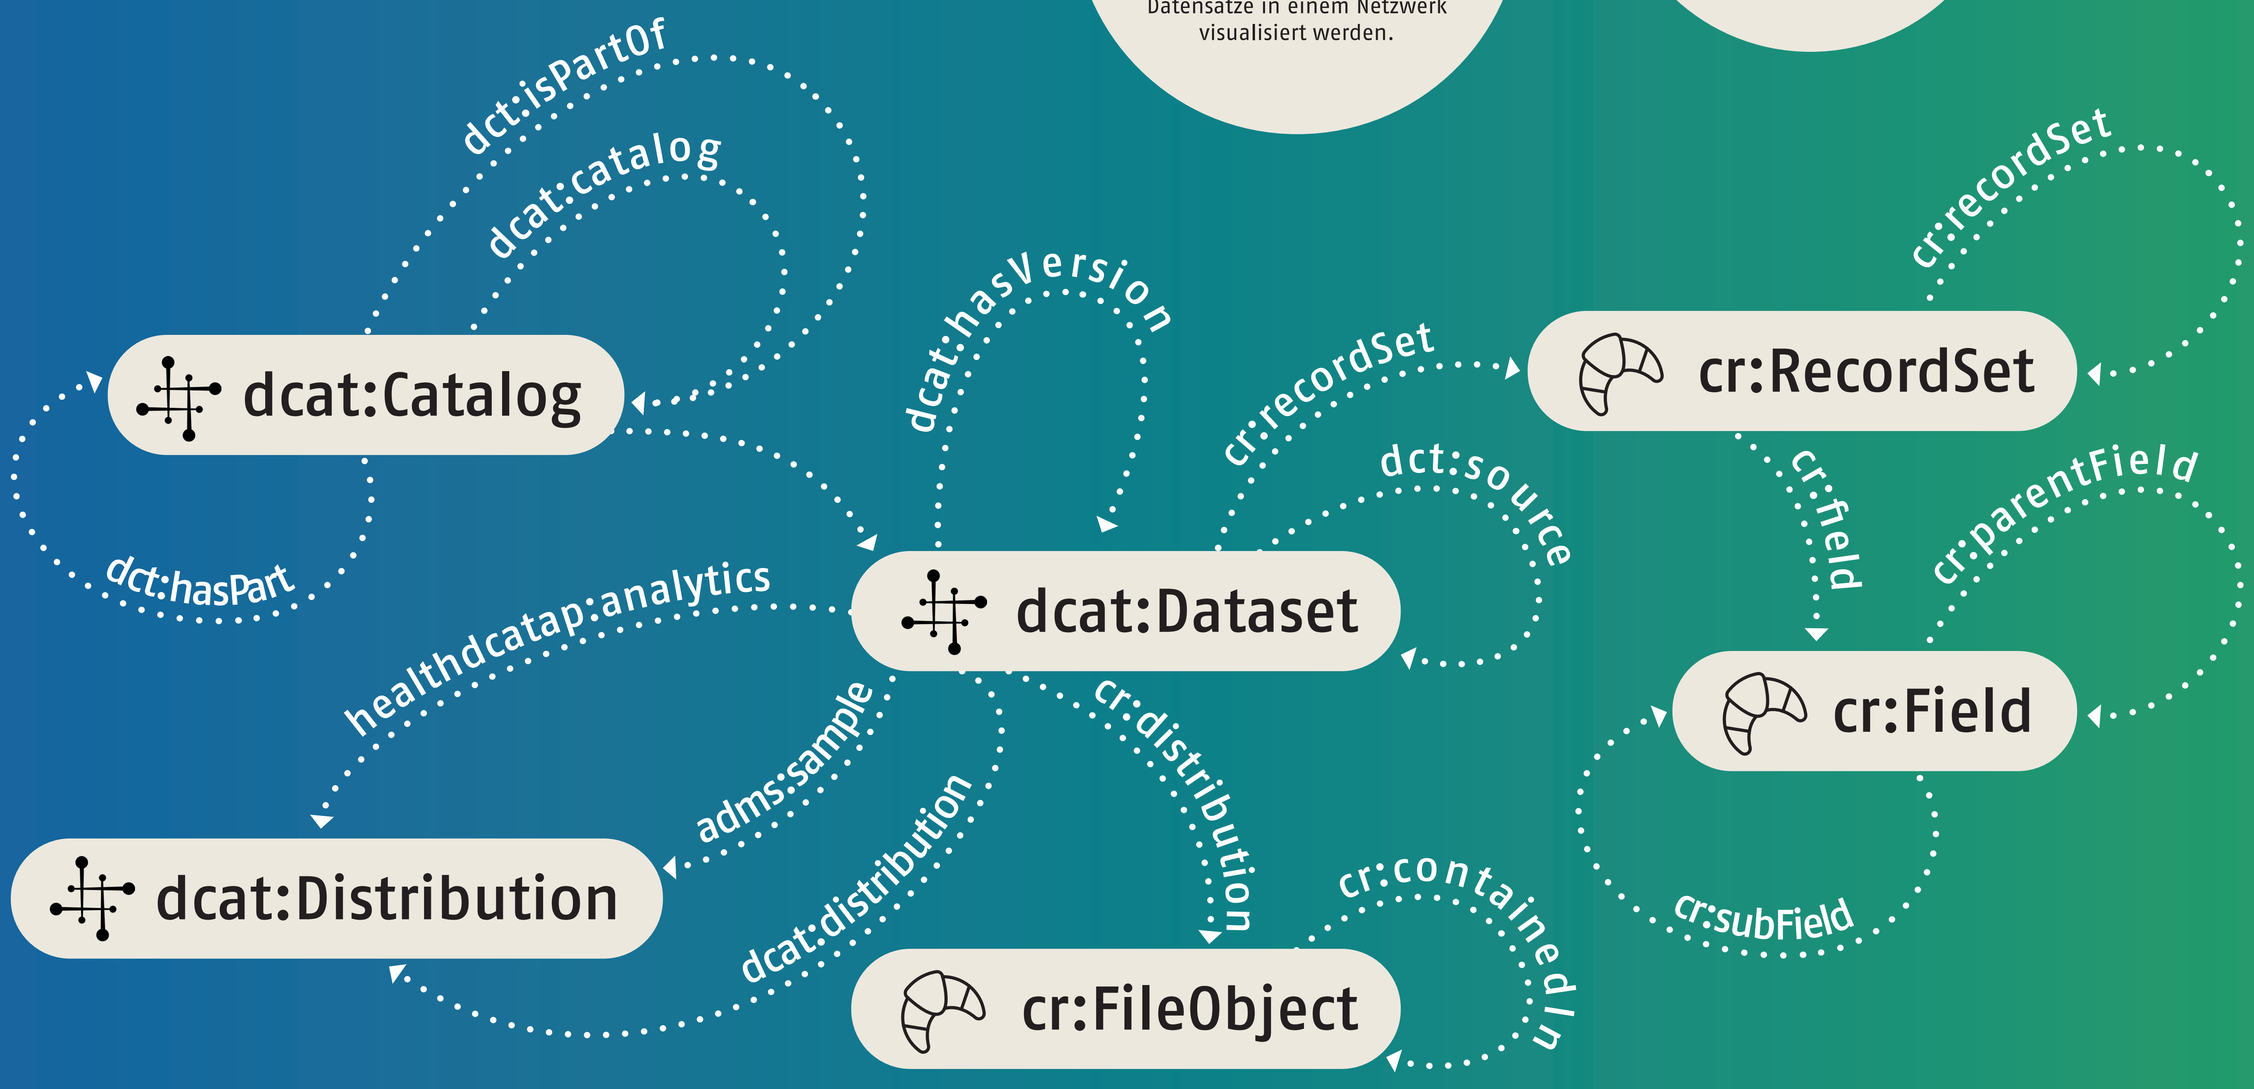
HealthDCAT-AP.de ist ein auf den Gesundheitssektor angepasstes Metadatenmodell, das von]init[im Rahmen der Post-COVID-Challenge zur Gründung des Dateninstitut des Bundes entwickelt wurde. Es stellt eine deutsche Ableitung und Erweiterung von HealthDCAT-AP dar, dem Metadatenstandard des EHDS.

Das Modell unterstützt im Sinne der FAIR-Prinzipien v.a. die Auffindbarkeit und die Zugänglichkeit. Damit vereinfacht es die Wiederverwendung von Forschungsdaten durch Mensch und Maschine.

HealthDCAT-AP.de bietet nicht nur eine hohe Anschlussfähigkeit an den Datenschatz des EHDS, sondern kann auch für die KI-fähige Katalogisierung der eigenen Daten verwendet werden.

HealthDCAT-AP.de hilft, Datensätze über ihre Metadaten mittels semantisch festgelegter Beziehungen – auch über das Gesundheitswesen hinaus – zu erschließen und zu verknüpfen. Mit einem sog. Wissensgraph können die Beziehungen der Datensätze in einem Netzwerk visualisiert werden.

Forschende können so gezielt Datensätze suchen sowie bis zur Datenfeldebene hinab erkennen, wie diese Datensätze aufgebaut und ob sie für ihre Fragestellung hilfreich sind. Das Modell wurde dazu mit datenhaltenden und datennutzenden Stellen erprobt.



Sekundärdatennutzung im EHDS

Die Vision des European Health Data Space ist die elektronische Erfassung von Gesundheitsdaten und deren Bereitstellung zum Zweck ärztlicher Versorgung (primäre Datennutzung) sowie medizinischer Forschung und valider Politikgestaltung (sekundäre Datennutzung). Je größere Mengen an Daten vorliegen, desto besser können (v.a. seltene) Erkrankungen erforscht und KI-Algorithmen trainiert werden.

Die europäische Joint Action TEHDAS2 wurde ins Leben gerufen, um Umsetzungshilfen zur EHDS-Verordnung bzgl. Sekundärnutzung in Form von Leitlinien, technischen Vorgaben und standardisierten Verfahren für die EU-Kommission und nationale Behörden zu liefern. Dazu gehören u.a. technische Spezifikationen für die nationalen Metadatenkataloge, die im Rahmen des EHDS in jedem Mitgliedsstaat umgesetzt werden müssen. In Deutschland wird dies vom BfArM verantwortet. Ein Metadatenkatalog ist ein Verzeichnis von beschreibenden Informationen (Metadaten) über Datensätze oder Datenquellen.

Im Rahmen von TEHDAS2 wurde daher HealthDCAT-AP entwickelt: Eine Erweiterung des europäischen Metadaten Standards DCAT-AP und zugeschnitten auf den Gesundheitsbereich. **HealthDCAT-AP.de** passt nicht nur HealthDCAT-AP auf Deutschland an und entwickelt es weiter, sondern gibt auch wertvollen Input zurück auf die europäische Ebene.

Ansatz von HealthDCAT-AP.de

Das Metadatenmodell **HealthDCAT-AP.de** ist ein semantisches Modell, das im Rahmen der Post-COVID-Challenge des Dateninstitutes des Bundes entwickelt wurde. Es handelt sich formal um eine nationale Ableitung des von TEHDAS2 entwickelten HealthDCAT-AP, bei dem das Modell um Elemente aus DCAT-AP.de sowie dem ML-Format Croissant erweitert wurde.

Um die Auffindbarkeit und Identifizierbarkeit medizinischer Daten, die verteilt und in sehr heterogenen Formaten und Standards vorliegen, zu verbessern, kann in **HealthDCAT-AP.de** bereits auf der Ebene der Metadaten eine Vielzahl an relevanten Informationen mitgeliefert werden. Damit soll eine Entscheidung über die Nachnutzbarkeit durch Wissenschaftler:innen und Mediziner:innen bereits vor Beantragung des Zugriffs auf die eigentlichen Daten unterstützt werden. **HealthDCAT-AP.de** ermöglicht für Distributionen die genaue Angabe der Strukturierung von Datenfeldern, die verwendeten Codelisten und die verwendeten Datenformate. Forschende können sich z.B. alle Datensätze anzeigen lassen, die ICD10-codiert sind und mehr als 5.000 Einträge beinhalten.

Die Entwicklung im Rahmen der Challenge fand unter Begleitung des WIG2 Instituts in engem Austausch mit relevanten Stakeholdern wie z.B. dem RKI statt. Ziel war, insbesondere die realen Anforderungen von Wissenschaftler:innen und Mediziner:innen bei der Nutzung von Gesundheitsdaten zu berücksichtigen, und im Sinne einer Standardisierung sowohl für Datenbereitstellende zugänglich als auch für Datennutzende praktikabel zu sein.

Kontakt: pf-healthdcat-ap@init.de
Website: HealthDCAT-AP.de

]init[